

Reality Subtitles

Tek cümlelik açıklama:

“Gürültülü ortamlarda sesi ve ağız hareketlerini birlikte kullanarak daha doğru canlı altyazı üretmek istiyorum.”

Neden bu konu?

“Hem erişilebilirlik açısından faydalı buluyorum hem de iOS, gerçek zamanlı sistemler ve görüntü işleme gibi ilgilendiğim alanları birleştiriyor.”

Ana araştırma sorusu:

Gürültülü ortamlarda audio + visual bilgi kullanımı, sadece audio kullanımına göre konuşma tanıma hatasını azaltıyor mu?

İkinci araştırma sorusu:

Gürültü seviyesine göre audio ve visual kanallara verilen ağırlığı değiştirmek, sabit ağırlıklı fusion yöntemine göre daha düşük hata oranı sağlıyor mu?

scope:

“Tek konuşmacı, telefon/laptop, canlı altyazı, 3 gürültü seviyesi.”

Seviye 1 – Sessiz / Baseline

- Sessiz oda.
- Arka planda belirgin konuşma, müzik, trafik vb. yok.
- İnsan konuşmacıyı rahatça anlayabiliyor.
- Amaç: sistemin ideal koşuldaki normal başarısını görmek.
- Örnek: yurttada/odada kapı kapalı, sadece konuşmacı konuşuyor.

Seviye 2 – Orta gürültü

- Arkada kafe uğultusu, insanların konuşması, hafif müzik gibi ses var.
- İnsan hâlâ konuşmacıyı anlayabiliyor ama dikkat etmesi gerekiyor.
- Burada audio-only sistemin hatalarının yavaş yavaş artmasını bekliyoruz.
- Biz de “görsel ağız bilgisi burada yardım ediyor mu?” diye bakıyoruz.

- Örnek: laptop/başka telefondan sabit seviyede “café noise” oynatmak.

Seviye 3 — Yüksek gürültü

- Arka plan konuşmaya yakın veya daha baskın.
- İnsan bazı kelimeleri kaçırmaya başlayabilir.
- Audio-only sistemin ciddi şekilde zorlanması beklenir.
- Eğer Reality Subtitles’ın avantajı olacaksa, en çok burada ortaya çıkmasını isteriz.
- Örnek: yüksek kafe/kalabalık/traffic noise.

şimdilik yapılmayacaklar:

“Meta gözlük, duygu analizi, çoklu konuşmacı, çeviri, sıfırdan model eğitme.”

makaleler

makale 1: <https://ieeexplore.ieee.org/abstract/document/8585066> (audio visual speech recognition)

1. Araştırmacılar ne yaptı?

Araştırmacılar, sesli veya sessiz yüz videolarından (dudak okuma) konuşulan doğal dil cümlelerini metne dökmek (transkripsiyon) için Transformer mimarisine dayalı derin öğrenme modelleri geliştirdiler. Ayrıca LRS2-BBC adında görsel-işitsel konuşma tanıma için yeni, büyük ölçekli bir veri seti oluşturup herkese açık olarak yayınladılar.

2. Hangi veri seti/setlerini ve model(ler)i kullandılar?

Araştırmacılar, bir ResNet görsel ön ucu (front-end) ve karakter düzeyinde LSTM dil modeli içeren, Bağlantıcı Zamansal Sınıflandırma (Connectionist Temporal Classification) kaybı (TM-CTC) ve diziden diziye (sequence-to-sequence) kayıp (TM-seq2seq) ile eğitilmiş Transformer tabanlı öz-dikkat (self-attention) modelleri oluşturdular. Sistemlerini LRS2-BBC, LRS3-TED ve MV-LRS veri setlerini kullanarak eğitip değerlendirdiler.

3. Ana sonuçlar nelerdi?

Yalnızca görsel kullanan en iyi dudak okuma modelleri, LRS2-BBC üzerinde %48,3'lük bir kelime hata oranına (word error rate) ulaşarak, önceki en ileri teknoloji (state-of-the-art) sonuçlarını %22'nin üzerinde bir farkla geliştirdi. Video ve ses kiplerini (modalities) birleştirmek, tekli kiplere kıyasla hata oranlarını düşürdü ve gürültülü ortamlarda doğruluğu önemli ölçüde artırdı.

makale 2: <https://ieeexplore.ieee.org/document/11434748> (AVSR noisy environment)

1. Araştırmacılar ne yaptı?

Araştırmacılar, hem ses hem de video girdileri bozulduğunda (corrupted) mevcut görsel-işitsel konuşma tanıma modellerinin nasıl performans gösterdiğini analiz ettiler. Görsel bir bozulma modelleme tekniği geliştirdiler ve sistemin en net bilgiye odaklanabilmesi için hangi girdi akışının daha güvenilir olduğunu belirleyen AV-RelScore adlı yeni bir model tanıttılar.

2. Hangi veri seti/setlerini ve model(ler)i kullandılar?

Yaklaşımlarını LRS2 ve LRS3 İngilizce görsel-işitsel veri setleri üzerinde test ettiler. Çerçeveleri (framework); özellik çıkarımı için ResNet18 görsel ve işitsel ön uçlarını (front-ends), çok modlu dikkat (multimodal attention) için bir Conformer kodlayıcıyı (encoder), metin tahmini için bir Transformer kod çözücüyü (decoder) ve kendi özel AV-RelScore modüllerini kullanmaktadır.

3. Ana sonuçlar nelerdi?

Önerilen AV-RelScore modeli, ağır şekilde bozulmuş ses ve görsel girdileri işlerken mevcut yöntemlerden daha iyi performans gösterdi. Ayrıca, tamamen temiz koşullarda en ileri teknoloji (state-of-the-art) sonuçlar elde ederek LRS2'de %4,1 ve LRS3'te %2,8 gibi düşük Kelime Hata Oranlarına (WER) ulaştı.

makale 3: [Hearing Lips: Improving Lip Reading by Distilling Speech Recognizers](#) (lip reading speech recognition)

1. Araştırmacılar ne yaptı? Araştırmacılar, önceden eğitilmiş bir konuşma tanıyıcısından (speech recognizer) elde edilen bilgiyi bir dudak okuma modeline aktararak dudak okumayı geliştirmek için Lip by Speech (LIBS) adında bir çerçeve (framework) oluşturdular. Bunu, ses ve video özelliklerini eşleştirmek (align) için hizalama ve filtreleme teknikleri kullanırken; dizi (sequence), bağlam (context) ve kare (frame) düzeylerinde çoklu ayrıntı seviyesine sahip (multi-granularity) bilgiyi damıtarak (distill) başardılar.
2. Hangi veri seti/setlerini ve model(ler)i kullandılar? Yaklaşımlarını, ek konuşma ses verileri için AISHELL ve LibriSpeech'in yanı sıra CMLR ve LRS2 dudak okuma veri setleri üzerinde değerlendirdiler. Modeller için, görsel özellik çıkarımı amacıyla Evrişimli Sinir Ağlarını (CNN'ler), Yinelemeli Sinir Ağları (GRU'lar ve LSTM'ler) ile birleştiren dikkat tabanlı (attention-based) diziden diziye (sequence-to-sequence) mimariler kullandılar.
3. Ana sonuçlar nelerdi? LIBS yöntemi, CMLR veri setinde karakter hata oranlarını %7,66 ve LRS2'de %2,75 oranında iyileştirerek temel (baseline) modelleri geride bıraktı ve en ileri teknoloji (state-of-the-art) performansına ulaştı. Bu çerçeve, sınırlı miktarda video verisiyle eğitildiğinde çok daha büyük performans artışları sağladı.

makale 4: [Large-Scale Visual Speech Recognition](#) (visual speech recognition)

1. Arařtırmacılar ne yaptı?

Arařtırmacılar, yaygın olarak dudak okuma olarak bilinen açık kelime hazneli (open-vocabulary) görsel konuşma tanıma için otomatik bir sistem oluřturdular. Devasa bir video veri setini derlemek için bir veri iřlem hattı (data pipeline) kurdular ve görsel dudak hareketlerini metne çeviren bir sinir ağı çerçevesi (framework) geliřtirdiler.

2. Hangi veri seti/setlerini ve model(ler)i kullandılar?

3.886 saatlik YouTube video kliplerinden oluřan Büyük Ölçekli Görsel Konuşma Tanıma (Large-Scale Visual Speech Recognition - LSVSR) veri setini oluřturup kullandılar ve ayrıca sistemlerini LRS3-TED veri seti üzerinde deęerlendirdiler. Fonemleri (ses birimlerini) tahmin etmek için 3 boyutlu evriřimleri (3D convolutions) ve çift yönlü LSTM'leri birleřtiren model mimarilerine Vision to Phoneme (V2P) adını verdiler; bu yapı aynı zamanda bir Sonlu Durum Dönüřtürücüsü (Finite State Transducer - FST) kelime kod çözücüsü (word decoder) ile eřleřtirilmiřtir.

3. Ana sonuçlar nelerdi?

V2P sistemi, %40,9'luk bir kelime hata oranına ulařarak hata oranları %86,4 ile %92,9 arasında deęiřen profesyonel insan dudak okuyucularından önemli ölçüde daha iyi performans gösterdi. Ayrıca LipNet ve Watch, Attend, and Spell gibi önceki otomatik dudak okuma modellerini geride bırakırken, ince ayar (fine-tuning) yapmadan LRS3-TED veri setinde yeni bir en ileri teknoloji (state of the art) seviyesi belirledi.

makale 5: <https://www.sciencedirect.com/science/article/pii/S221509862200115X> (Turkish lip reading)

1. Arařtırmacılar ne yaptı?

Arařtırmacılar, ses olmadan video karelerinden konuşulan ifadeleri tanımak için derin öğrenme yöntemlerini kullanan otomatik bir Türkçe dudak okuma sistemi geliřtirip deęerlendirdiler. Bunu başarmak için, ilk açık Türkçe dudak okuma veri setlerini oluřturdular ve Evriřimli Sinir Ağları (CNN) kullanarak görsel özellikleri çıkaran ve bunları Çift Yönlü Uzun Kısa Süreli Bellek (Bi-LSTM) ağları kullanarak sınıflandıran bir iřlem hattı (pipeline) kurdular.

2. Hangi veri seti/setlerini ve model(ler)i kullandılar?

24 konuşmacıdan kaydedilen, biri 111 kelime ve dięeri 113 cümle içeren iki yeni Türkçe veri seti oluřturdular. Sistemleri için, önceden eęitilmiř CNN modellerini (ResNet-18 ve GoogleNet dahil) kullanarak video karelerinden görsel özellikler çıkardılar ve zamansal dizileri (temporal sequences) bir Bi-LSTM modeli kullanarak sınıflandırdılar.

3. Ana sonuçlar nelerdi?

ResNet-18 ve Bi-LSTM kombinasyonu en yüksek performansı göstererek kelime veri setinde %84,09 ve cümle veri setinde %88,55 doğruluğa ulaştı. Yalnızca ses kullanan ve görsel-işitsel konuşma tanıma arasındaki bir karşılaştırma makalede açıkça belirtilmemiştir.

Makale	Bana ne öğretti?	Projemde hangi kararı etkiliyor?
1. Audio-Visual Speech Recognition	Audio + visual birlikte kullanılabilir ve özellikle gürültüde fayda sağlayabilir	Projede sadece mikrofon değil, kamera/dudak bilgisini de düşünmem mantıklı mı? → Evet
2. AVSR Noisy Environment	Audio ve video her zaman aynı kalitede değil; hangisi güvenilirse ona daha çok ağırlık verilebilir	Fusion kısmında “her zaman %50 ses + %50 görüntü” yapmak zorunda değilim → dinamik ağırlıklandırma düşünebilirim
3. Hearing Lips	Güçlü bir speech modelinden lip-reading modeline bilgi aktarılabilir	Visual modelim zayıfsa veya veri azsa, knowledge distillation gibi yöntemler ileride seçenek olabilir
4. Large-Scale Visual Speech Recognition	Sadece görüntüden de konuşma tanınabiliyor ama büyük veri çok önemli	Visual-only bir baseline mümkün; ayrıca dataset büyüklüğünün kritik olduğunu anlıyorum
5. Turkish Lip Reading	Türkçe lip-reading yapılabilir ama veri setleri daha küçük ve sınırlı	Türkçe kısmında hazır veri/model bulmanın zor olabileceğini görüyorum; proje kapsamını buna göre gerçekçi tutuyorum

Şu aşamada en doğrudan kullanacağım fikirler:

audio-only bir baseline oluşturmak,

visual tarafı ayrı deęerlendirmek

ve daha sonra ikisini fusion ile birleřtirmek.

Noise altında performansı ayrıca test etmek istiyorum.

Knowledge distillation ve reliability-based fusion ise proje ilerlerse deęerlendirebileceęim daha ileri yöntemler.

Ses / Konuşma Tanıma Araçlar: (Mikrofon → Speech Framework / Whisper → audio transcript)

Seçenek A — Apple Speech Framework (SpeechAnalyzer)

Düşük gecikme süresi ve kolay Swift entegrasyonu ile cihaz içi (on-device) yerel konuşma tanıma.

Seçenek B — OpenAI Whisper

Diller ve aksanlar genelinde daha fazla esneklik ve sağlamlık sunan çok dilli konuşma tanıma.

Görsel Konuşma Tanıma Araçlar: (Kamera → lip-reading model → visual information)

Seçenek A — AV-HuBERT Gürültülü ortamlarda transkripsiyonu (metne dökme) iyileřtirmek için dudak hareketlerini mikrofon sesiyle birleřtirebilen görsel-iřitsel konuşma tanıma modeli.

Seçenek B — Auto-AVSR Yüz/dudak hareketlerini doğrudan metne dönüřtürerek, ses kalitesi zayıf olduęunda veya ses tamamen kullanılamadıęında bile konuşma tanımayı saęlayan görsel konuşma tanıma modeli.

audio + visual → fusion → final subtitle

Veri Seti Adayları

https://www.robots.ox.ac.uk/~vgg/data/lip_reading/

İngilizce – LRS3-TED TED/TEDx videolarından alınan doğal İngilizce cümleler içeren, büyük ölçekli ve doğal ortamlarda (in-the-wild) kaydedilmiş görsel-işitsel konuşma tanıma veri seti.

<https://aclanthology.org/L12-1262/>

Türkçe – SUTAV Özellikle AVSR (Görsel-İşitsel Konuşma Tanıma) araştırmaları için tasarlanmış; konuşulan kelimeleri, sayıları ve cümleleri içeren Türkçe görsel-işitsel konuşma veritabanı. Veri setine erişilebilirliğin doğrulanması gerekmektedir.

<https://data.mendeley.com/datasets/4t8vs4dr4v/1>

Türkçe Yedek – Türkçe Görsel Dudak Okuma Veri Seti 10 yaygın kelime/ifade genelinde 2.335 örnek içeren, herkese açık, gerçek dünya Türkçe görsel konuşma veri seti.

İlk aşamada pretrained modeller kullanarak çalışan bir prototype oluşturmayı planlıyorum. Datasetleri önce evaluation için kullanacağım. Eğer özellikle Türkçe visual speech recognition performansı yetersiz kalırsa, ikinci aşamada Türkçe veriyle fine-tuning yapmayı düşünebilirim.

1. Evaluation → Hazır modeli test edersin.
2. Comparison → Audio-only, visual-only ve audio-visual sonuçlarını aynı veri üzerinde karşılaştırırsın.
3. Fine-tuning → Hazır model Türkçede kötü çalışıyorsa, Türkçe veriyle biraz uyarlırsın.
4. Prototype validation → Sistemin gerçekten işe yarayıp yaramadığını kontrollü biçimde gösterirsin.

SORULAR?

Hazır model kullanmak uygun mu?

Türkçe dataset yetersizse İngilizce benchmark olur mu?

ana akademik değerlendirmeyi İngilizce LRS3 benchmark üzerinde yapıp, uygulama demosunda Türkçe audio desteği göstermem uygun olur mu; yoksa final sistemin de tamamen Türkçe olması mı bekleniyor?

Özgün katkıyı fusion yönteminde yapmam uygun mu?

Deney için kaç kişi / ne kadar veri yeterli?

gelecek hafta?

1. hafta sonu güncellemeler

- ilk aşamada whisper ile çalışan mobile app yapıyoruz
- türkçe olacak
- ilk amaç ortaya ürün çıkarmak araştırma tarafı sonra