

Gürültülü Ortamlarda Gerçek Zamanlı Audio-Visual Speech Recognition Tabanlı Altyazı Sistemi

Kısa Araştırma ve Proje Öneri Raporu

1. Konu ve Problem Tanımı

Bu projede, bir konuşmacının ses bilgisini ve ağız hareketlerinden elde edilen görsel konuşma bilgisini birlikte kullanarak gerçek zamana yakın altyazı üreten mobil bir prototip geliştirilmesi amaçlanmaktadır. Temel problem, yalnızca sese dayalı konuşma tanıma sistemlerinin gürültülü ortamlarda daha fazla hata yapabilmesidir. Audio-Visual Speech Recognition (AVSR) çalışmaları, dudak ve ağız hareketlerinden gelen görsel bilginin özellikle gürültülü koşullarda ses bilgisini tamamlayabildiğini göstermektedir [1][2]. Projenin ilk sürümü tek konuşmacı ve kontrollü gürültü koşullarıyla sınırlandırılacaktır.

2. Araştırma Sorusu ve Hipotez

Ana araştırma sorusu şudur: “Ses kalitesi düştüğünde, görsel konuşma bilgisini de kullanan bir sistem yalnızca ses kullanan bir speech-to-text sistemine göre daha düşük transkripsiyon hatası sağlayabilir mi?” Başlangıç hipotezi, gürültü seviyesi arttıkça audio-only sistemin hata oranının artacağı; ağız hareketlerinden elde edilen görsel bilginin uygun biçimde birleştirilmesiyle bazı gürültü koşullarında bu hatanın azaltılabileceğidir. Özgün katkı hedefi, mobil cihazda uygulanabilecek basit ve açıklanabilir bir audio-visual fusion yaklaşımının tasarlanması ve baseline ile karşılaştırılmasıdır. Kesin özgünlük iddiası ilk literatür taramasından sonra netleştirilecektir.

3. Önerilen Yöntem ve Kapsam

- iPhone/laptop üzerinden tek konuşmacının kamera ve mikrofon verisinin eş zamanlı alınması.
- Audio-only speech-to-text sisteminin baseline olarak kurulması.
- Yüz/ağız bölgesinin belirlenmesi ve önceden eğitilmiş bir visual-speech/lip-reading modelinden yardımcı çıktı alınması.
- Ses ve görsel çıktıların confidence/kalite temelli bir fusion yöntemiyle birleştirilmesi.
- Sessiz, orta ve yüksek gürültü koşullarında WER, CER ve uçtan uca gecikmenin ölçülmesi.

Sıfırdan büyük bir yapay zekâ modeli eğitilmeyecektir; önceden eğitilmiş modellerden yararlanılacak ve çalışma sistem entegrasyonu, gerçek zamanlı işleme, fusion ve karşılaştırmalı deney üzerine kurulacaktır. Apple AVFoundation iOS üzerinde kamera ve mikrofon akışlarına canlı erişim sağlamaktadır [4]. Türkçe visual speech kaynakları sınırlıdır; 2023 tarihli açık bir Türkçe lip-reading veri seti 2.335 örnek ve 10 kelime/ifadeden oluşmaktadır [3]. Bu nedenle gerekirse visual-speech benchmark deneyleri İngilizce üzerinde de yürütülebilecektir.

4. Konuyu Seçme Nedenim

Bu konuyu seçme nedenim, gerçek bir kullanıcı problemine dokunurken Bilgisayar Mühendisliği açısından mobil uygulama geliştirme, gerçek zamanlı audio/video işleme, bilgisayarlı görü, konuşma tanıma ve multimodal sistemleri ölçülebilir bir prototipte birleştirmesidir. Projenin ileri aşamalarda işitme erişilebilirliği, konferans/tiyatro altyazısı ve akıllı gözlük uygulamalarına genişleme potansiyeli bulunmaktadır. Bununla birlikte altı aylık çalışma, tek kişi tarafından tamamlanabilecek şekilde tek konuşmacı, sınırlı gürültü koşulları ve önceden eğitilmiş modellerle sınırlandırılmıştır.

5. Beklenen Çıktı ve Çalışma Planı

İlk aşamada literatür taraması ve audio-only canlı altyazı prototipi oluşturulacaktır. Ardından kamera akışı, ağız bölgesi tespiti ve visual-speech bileşeni eklenecek; iki modalite senkronize edilerek fusion yöntemi geliştirilecektir. Son aşamada kontrollü gürültü deneyleri, mobil optimizasyon ve raporlama

yapılacaktır. Altı ay sonunda hedef; tek konuşmacıya bakıldığında canlı altyazı üreten, audio-only baseline ile aynı test setinde karşılaştırılmış ve WER/CER/gecikme sonuçları raporlanmış çalışan bir prototip elde etmektir. Akıllı gözlük, duygu analizi, çeviri ve çoklu konuşmacı desteği bu projenin zorunlu teslim kapsamına dahil değildir.

Kaynakça

- [1] Shi, B., Hsu, W.-N., Lakhotia, K., & Mohamed, A. (2022). Learning Audio-Visual Speech Representation by Masked Multimodal Cluster Prediction (AV-HuBERT). ICLR 2022. <https://openreview.net/forum?id=Z1Qlm11uOM>
- [2] Hu, Y., Li, R., Chen, C., Qin, C., Zhu, Q.-S., & Chng, E. S. (2023). Hearing Lips in Noise: Universal Viseme-Phoneme Mapping and Transfer for Robust Audio-Visual Speech Recognition. ACL 2023. <https://doi.org/10.18653/v1/2023.acl-long.848>
- [3] Berkol, A., Tümer-Sivri, T., Pervan-Akman, N., Çolak, M., & Erdem, H. (2023). Visual Lip Reading Dataset in Turkish. Data, 8(1), 15. <https://doi.org/10.3390/data8010015>
- [4] Apple Developer Documentation. AVFoundation — Audio and Video Capture. <https://developer.apple.com/documentation/avfoundation/audio-and-video-capture>